

# **Wprowadzenie do uczenia maszynowego część I**

Franciszek Górski 2021

# Czym jest uczenie maszynowe?

- Uczenie maszynowe - proces poprawy wyników algorytmu wraz ze zdobywanym doświadczeniem, które to doświadczenie pozyskiwane jest z danych.
- Proces pozyskiwania doświadczenia nazywany jest uczeniem się.
- W czasie uczenia tworzony jest model na podstawie danych uczących.

# Dane uczące

Jeżeli model ma zdobywać doświadczenie z danych, to dane muszą zawierać informację. Dlatego w Informatyce dane przedstawiane są w postaci zbioru parametrów np. - dane opisujące różne komputery

Pamięć RAM	Pamięć VRAM GPU	Liczba rdzeni CPU	Taktowanie CPU
8	0	4	2,4
16	6	8	2,5
8	2	8	2,3

# Etykiety danych

Przedstawione dane mają z kolei przypisane etykiety. Załóżmy, że prezentowany przez nas zbiór ma służyć opisaniu cen komputerów w zależności od ich parametrów:

Pamięć RAM	Pamięć VRAM GPU	Liczba rdzeni CPU	Taktowanie CPU	Cena
8	0	4	2.4	1500
16	6	8	2.5	3000
8	2	8	2.3	1900

# Dane uczące

Pamięć RAM	Pamięć VRAM GPU	Liczba rdzeni CPU	Taktowanie CPU
8	0	4	2.4
16	6	8	2.5
8	2	8	2.3

= **X**

Cena
1500
3000
1900

= **y**

**X** - macierz liczb rzeczywistych o wymiarach 3x4 (3 przykłady danych, każdy opisany 4 parametrami)

**y** - wektor liczb rzeczywistych 3x1

# Dane uczące - nasze uproszczenie

Pamięć RAM
8
16
8

=  $X$

$X$  - macierz (wektor) liczb rzeczywistych o wymiarach  $3 \times 1$  na nasze potrzeby założmy 1 parametr opisujący dane

$y$  - wektor liczb rzeczywistych  $3 \times 1$

Cena
1500
3000
1900

=  $y$

# Hipoteza $h(x)$

Przykładowa hipoteza dla naszego przypadku - cena laptopów na rynku:

$$h(x) = a \cdot x + b$$

Nasze dane:

$$X[0] = [8]$$

$$h(X[0]) = 8a + b$$

$$X[1] = [16]$$

$$h(X[1]) = 16a + b$$

$$X[2] = [8]$$

$$h(X[2]) = 8a + b$$

# Inicjalizacja wag w hipotezie $h(x)$

Nasza hipoteza:  $h(x) = a \cdot x_1 + b$

**Nasze wyniki:**

$$h(X[0]) = 8a + b$$

$$h(X[1]) = 16a + b$$

$$h(X[2]) = 8a + b$$

**Inicjalizacja wag - wektor parametrów  $\theta$  (theta)**

$$\theta = [a, b]$$

$$\theta = [100, 150]$$

**Etykiety danych:**

$$y[0] = 1500$$

$$y[1] = 3000$$

$$y[2] = 1900$$

**Wyniki predykcji:**

$$y\_pred[0] = 800 + 150 = 950$$

$$y\_pred[1] = 1600 + 150 = 1750$$

$$y\_pred[2] = 800 + 150 = 950$$





# Jak zmierzyć błąd algorytmu? - funkcja kosztu $L(y, y\_pred)$

**Nasze wyniki predykcji:**

$$y\_pred[0] = 800 + 150 = 950$$

$$y\_pred[1] = 1600 + 150 = 1750$$

$$y\_pred[2] = 800 + 150 = 950$$

**Przykładowa funkcja kosztu  $l(y[i], y\_pred[i])$ :**

$$l(y[i], y\_pred[i]) = |y[i] - y\_pred[i]|$$

lub

$$l(y[i], y\_pred[i]) = (y[i] - y\_pred[i])^2$$

**Posiadane etykiety danych:**

$$y[0] = 1500$$

$$y[1] = 3000$$

$$y[2] = 1900$$

**MSE (mean square error):**

$$L(y, y\_pred) = 1/n * \sum_i \{(y[i] - y\_pred[i])^2\}$$

# Jak zmierzyć błąd algorytmu? - funkcja kosztu $L(y, y\_pred)$ c.d.

**Nasze wyniki predykcji:**

$$y\_pred[0] = 800 + 150 = 950$$

$$y\_pred[1] = 1600 + 150 = 1750$$

$$y\_pred[2] = 800 + 150 = 950$$

**Nasza funkcja kosztu  $L(y, y\_pred)$**

**MSE (mean square error):**

$$L(y, y\_pred) = 1/n * \sum_i [(y[i] - y\_pred[i])^2]$$

**Posiadane etykiety danych:**

$$y[0] = 1500$$

$$y[1] = 3000$$

$$y[2] = 1900$$

**Funkcja kosztu  $L(y, y\_pred)$**

$$\begin{aligned} L(y, y\_pred) &= \frac{1}{3} * [(1500 - 950)^2 + (3000 - 1750)^2 + (1900 - 950)^2] = \\ &= \frac{1}{3} * [302500 + 1562500 + 902500] = \\ &= \frac{1}{3} * 2767500 \sim \mathbf{922500} \end{aligned}$$

# Funkcja kosztu $L(y, y\_pred)$

Funkcja kosztu  $L(y, y\_pred) = 922500$  - to nie jest dobry wynik :)

**Co jest naszym celem?** - minimalizacja funkcji kosztu  $L(y, y\_pred)$  czyli  **$\min L(y, y\_pred)$**

**Co jest naszym celem?** - minimalizacja funkcji kosztu  $L(y, y\_pred)$  czyli  **$\min L(y, y\_pred)$**

**Jak to zrobić?** - zmieniając parametry  $\theta = [a = 100, b = 150]$  przy pomocy metody gradientu prostego - ***Gradient Descent***

# Metoda gradientu prostego (Kocioł pod Polskim Grzebieniem, Tatry Słowackie)



Autor: Franciszek Górski

# Metoda gradientu prostego

Jest wiele metod optymalizujących funkcję, my skupimy się na jednej z najpopularniejszych z nich - metodzie gradientu prostego.

Wyobraźmy sobie dolinę wśród gór w której chcemy znaleźć najniżej położony punkt, który określimy jako minimum globalne.

W tym celu zastosujemy właśnie metodę gradientu prostego, która licząc pochodne cząstkowe parametrów optymalizowanej funkcji wskazuje kierunek **wzrostu** funkcji!




# Metoda gradientu prostego

Wzrostu? Ale my chcemy minimalizować funkcję! - Dlatego będziemy wykorzystywali **zanegowaną** wartość gradientu - **negacja wzrostu == spadkowi**

Startujemy w punkcie A i korzystając z zanegowanej wartości gradientu kierujemy się w dół zbocza doliny.

Aż do punktu D, który jest najniżej położonym punktem w dolinie.

Uwaga na lokalne minima np. w punkcie C!



Autor: Franciszek Górski

# Metoda gradientu prostego - obliczenia

$$L(y, y\_pred) = 1/n * \sum_i \{(y[i] - y\_pred[i])^2\}$$

$$\nabla L(a, b) = \{\partial a, \partial b\} =$$

$$h(x) = a*x_1 + b, h(x[i]) = y\_pred[i]$$

$$\partial a = - 2/n * \sum_i \{x[i]*(y[i] - a*x[i] + b)\}$$

$$\theta = [a, b]$$

$$\partial b = - 2/n * \sum_i \{(y[i] - a*x[i] + b)\}$$

$$L(y[i], x[i], \theta) = 1/n * \sum_i \{(y[i] - a*x[i] - b)^2\}$$

$$\theta_0 = [a_0 = 100, b_0 = 150]$$

$$a_1 := a_0 - \eta * \partial a = a_0 - \eta * (- 2/n * \sum_i \{x[i]*(y[i] - a_0*x[i] + b_0)\}) = a_0 - \eta * (- 2/n * \sum_i \{x[i]*(y[i] - y\_pred[i])\})$$

$$b_1 := b_0 - \eta * \partial b = b_0 - \eta * (- 2/n * \sum_i \{(y[i] - a_0*x[i] + b_0)\}) = b_0 - \eta * (- 2/n * \sum_i \{(y[i] - y\_pred[i])\})$$

$\eta$  (eta)- współczynnik uczenia (ang. *learning rate*)

# Metoda gradientu prostego - obliczenia

$$\theta_0 = [a_0 = 100, b_0 = 150]$$

$$y = [1500, 3000, 1900]$$

$$y_{pred} = [950, 1750, 950]$$

$$\eta = 0.001$$

Nasze nowe parametry  $\theta_1$ :

$$\theta_1 = [a_1 = -78,66, b_1 = -175]$$

$$\begin{aligned} a_1 &:= 100 - 0.001 * \frac{2}{3} * [8 * (1500 - 950) + 16 * (3000 - 1750) + 8 * (1900 - 950)] = 100 - 0.001 * \frac{2}{3} * \\ &[8 * 550 + 16 * 1250 + 8 * 950] = 100 - 0.001 * \frac{2}{3} * (4400 + 20000 + 7600) = 100 - 0.001 * \frac{2}{3} * 32000 \\ &= 100 - \frac{2}{3} * 32 \approx 100 - 21,33 = -78,66 \end{aligned}$$

$$\begin{aligned} b_1 &:= 150 - 0.001 * \frac{2}{3} * [150 * (1500 - 950) + 150 * (3000 - 1750) + 150 * (1900 - 950)] = 150 - 0.001 * \\ &\frac{2}{3} * [150 * 550 + 150 * 1250 + 150 * 950] = 150 - 0.001 * \frac{2}{3} * (82500 + 187500 + 142500) = 150 - \\ &0.001 * \frac{2}{3} * 412500 = 150 - \frac{2}{3} * 412,5 \approx 150 - 275 = -175 \end{aligned}$$



# Regresja liniowa jednej zmiennej

Pamięć RAM
8
16
8

= X

Omawiany przez nas przykład określany jest jako **regresja liniowa jednej zmiennej**.

Cena
1500
3000
1900

= y

Regresja oznacza, że **zbiorem wartości** funkcji są **liczby rzeczywiste**.

W ramach uproszczenia przedstawiliśmy regresję dla hipotezy z jedną zmienną niezależną x.

# Regresja liniowa wielu zmiennych

Pamięć RAM	Pamięć VRAM GPU	Liczba rdzeni CPU	Taktowanie CPU
8	0	4	2.4
16	6	8	2.5
8	2	8	2.3

= X

Cena
1500
3000
1900

= y

W prawdziwych problemach spotkacie się jednak z danymi zawierającymi wiele zmiennych niezależnych x, czyli wieloma parametrami danych.

# Regresja liniowa wielu zmiennych

$$h(x) = a*x4 + b*x3 + c*x2 + d*x1 + e$$

I wtedy taka hipoteza zostanie wykorzystana do treningu modelu, reszta kroków pozostaje niezmienna ...

Jednak w przypadku wielu zmiennych model liniowy może okazać się niewystarczający, ale o tym kiedy indziej ...

# Klasyfikacja

- Zbiorem wartości zamiast liczb rzeczywistych są dyskretne (z góry określone) wartości np. liczby [1, 2, 3]
- Klasyfikacja polega na przypisania danych do konkretnych klas
- Tak samo jak w regresji tutaj też jest hipoteza, jej parametry, funkcja kosztu i optymalizacja parametrów np. metodą gradientu prostego
- Inne są jednak hipotezy i funkcje kosztu

# Klasyfikacja - dane

Pamięć RAM	Pamięć VRAM GPU	Liczba rdzeni CPU	Taktowanie CPU
8	0	4	2.4
16	6	8	2.5
8	2	8	2.3

= X

Klasa jakości (1 -3)
1
3
2

= y


Jak widać teraz te same dane zostały przypisane do jednej z 3 klas określających poziom “możliwości” poszczególnych laptopów

# Klasyfikacja - hipoteza

Jako hipotezy w klasyfikacji wykorzystuje się funkcje logistyczne takie jak sigmoid, tangens hiperboliczny czy ReLu.

$$\text{sigmoid}(x) = 1 / (1 + e^{-x})$$

Zbiór wartości :  $(0, 1)$  albo  $(-1, 1)$



# Klasyfikacja - funkcja kosztu

*Funkcja kosztu ma postać:*

$$L(y, y\_pred) = 1/n * \sum_i [y[i] * (-\log(y\_pred[i])) + (1 - y[i]) * (-\log(1 - y\_pred[i]))]$$

gdzie  $y\_pred[i] = \text{sigmoid}(x[i]) = 1 / (1 + e^{-x[i]})$

# Pytania?

Jeśli nie to ...

pora na krótką prezentację w Colabie